

Задачи компьютерного зрения: семантическая сегментация



Машинное обучение
Глубокое обучение

04

О чём эта лекция

Тема с большим количеством инженерии и малым — математики; лекция обзорная: цель — общее представление, за деталями — статьи.

- **Постановка.** Ограничивающие рамки + классы; чем задача сложна.
- **Метрика.** mAP: IoU, precision-recall, два-три усреднения.
- **Двухстадийные детекторы.** R-CNN → Fast R-CNN → Faster R-CNN (+ FPN).
- **Одностадийные.** YOLO, SSD, RetinaNet и focal loss.
- **Anchor-free.** FCOS и куда всё движется.

Этой лекцией завершается блок «регулярной решётки» — дальше множества и графы.

Постановка задачи

Дана картинка — нужно обвести **ограничивающими прямоугольниками** (bounding boxes) все объекты и назвать класс каждого из predetermined списка.

- Детектируем «вещи» (things: люди, машины, знаки), а не «материю» (stuff: небо, дорога) — для неё есть сегментация.
- Разметка дешёвая, почти как в классификации: рамки рисовать легко.
- Выборок много: Pascal VOC, MS COCO (~200 тыс. изображений, 80 классов, 500 тыс. объектов), поперх — LVIS (>1000 классов).

Почему это сложно

- **Неизвестно число объектов:** один, десять или ни одного — выход переменного размера.
- **Окклюзии и вложенность:** мотоцикл и его колёса — несколько прогнозов разного масштаба для одной области.

А если бы объект был ровно **один** — задача тривиальна:

$$\mathcal{L} = \underbrace{\text{кросс-энтропия}}_{\text{метка класса}} + \lambda \cdot \underbrace{\sum (\text{выход} - \text{истинная рамка})^2}_{\text{регрессия } (x, y, w, h)}$$

Классификация + регрессия четырёх чисел. Все дальнейшие ухищрения — из-за «сколько-то» объектов.

Метрика: какие бывают ошибки

При обучении минимизируем дифференцируемую функцию потерь; вопрос — как оценивать готовый детектор. Видов ошибок четыре:

- 1) ошибка в **метке класса**;
- 2) ошибка в **положении**: объект найден, рамка сдвинута;
- 3) **ложный прогноз**: рамка там, где ничего нет;
- 4) **множественное срабатывание**: несколько рамок на один объект.

Всё это собирается в один критерий — **mean Average Precision (mAP)**, «дважды усреднённую точность».

IoU, precision и recall

Локализация: мера Жаккара (IoU) из прошлой лекции — пересечение рамок к объединению; используется на каждом шагу.

Классификация (фиксируем класс, например «знак стоп»):

$$\text{precision} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN}.$$

Все четыре вида ошибок уже здесь: FP — рамка не на объекте, с IoU ниже порога *или дублирующая*; FN — объект не найден *или найден с уверенной ошибкой класса*.


Порог по уверенности двигает баланс: выше порог $\Rightarrow$ precision растёт, recall падает. Нужна величина, не зависящая от порога.

PR-кривая и AP



Сортируем прогнозы класса по уверенности;
правильность — по IoU с истиной ($> 0,5$):

№	Верно?	Prec.	Rec.
1	да	1,00	0,2
2	да	1,00	0,4
3	нет	0,67	0,4
4	нет	0,50	0,4
5	нет	0,40	0,4
6	да	0,50	0,6
7	да	0,57	0,8



AP — площадь под огибающей (по сетке recall 0, 0,1, ..., 1);

$$\text{mAP} = \frac{1}{K} \sum_{k=1}^K \text{AP}_k$$

+ иногда усреднение по порогам IoU.

До сетей: скользящее окно



Классификация перебором: окно движется по всем позициям, масштабам (пирамида копий) и соотношениям сторон.

Две темы проходят отсюда через всю лекцию:

- **NMS** — подавление семейства сработавших окон вокруг объекта;
- **дисбаланс классов** — фона на порядки больше.




Hard negative mining: прогнали детектор → собрали трудные ложные срабатывания → доучили. Стоит запомнить — у него будет наследник.

R-CNN (2013): регионы-кандидаты

Два шага:

- выделить ~ 2000 **регионов-кандидатов** (regions of interest) — пусть с запасом;
- каждый регион привести к 224×224 (warp) и классифицировать свёрточной сетью.

2013 год: сетям ещё не доверяли — CNN только **извлекает признаки**, поверх работают SVM (по классификатору на класс) и линейные регрессоры поправок.



Girshick et al., 2013

Генерация кандидатов: selective search



Досетевая иерархическая кластеризация:

- суперпиксели постепенно сливаются в регионы;
- признаки рукотворные: цвет, текстура, позиция;
- плюс отсев дублей.

Работает, но в обучении сети не участвует
— скоро мы от него откажемся.



Figure 2: Two examples of our selective search showing the necessity of different scales. On the left we find many objects at different scales. On the right we necessarily find the objects at different scales as the girl is contained by the tv.

Uijlings et al., 2013

R-CNN: разметка и обучение

Метки регионам — через IoU, причём на разных стадиях по-разному.

- **Дообучение CNN:** позитив — регион с $\text{IoU} \geq 0,5$; батч — 32 объектных + 96 фоновых окон (ресемплинг против дисбаланса).
- **SVM:** позитивы — *сами истинные рамки*; фон — $\text{IoU} < 0,3$ со всеми; серая зона игнорируется. Порог 0,5 здесь ронял mAP на 5 пунктов.
- **Регрессоры:** учатся на парах с $\text{IoU} \geq 0,6$ — правим только то, что почти попало.

Обучение — три последовательные, по сути независимые стадии.

Регрессия рамок: параметризация

Регион $(\hat{x}, \hat{y}, \hat{w}, \hat{h})$, истинная рамка (x, y, w, h) ; целевые значения:

$$\left(\frac{x - \hat{x}}{\hat{w}}, \frac{y - \hat{y}}{\hat{h}}, \ln \frac{w}{\hat{w}}, \ln \frac{h}{\hat{h}} \right)$$

- Сдвиги — в долях размера региона, размеры — логарифмами отношений: всё **безразмерно**, один регрессор правит и большие, и маленькие рамки.
- Почему логарифм? Важен *порядок* изменения размера: «вдвое больше» и «вдвое меньше» — симметричные шаги $\pm \ln 2$, и квадратичный лосс штрафует их одинаково.

Эта параметризация — во всех детекторах лекции.

Тест: подавление немаксимумов (NMS)




На тесте: сгенерировать регионы → прогнать через сеть → вероятности классов и поправки → **жадное подавление немаксимумов**:

- фоновые регионы выбрасываем;
- в рамках класса: два прогноза пересекаются по IoU сильнее порога (0,5–0,7)
⇒ остаётся более уверенный;
- регион отнесён к двум классам ⇒ берём класс с максимальной уверенностью.

Главная беда R-CNN — скорость: тысячи регионов × полный прогон сети на *каждый*. Детектору положено работать на лету — а тут десятки секунд на кадр.

Fast R-CNN (2015): одна сеть на картинку



- Сеть применяется к картинке **один раз**; регионы (пока от selective search) проецируются на карту признаков по относительным координатам.
- Одна голова вместо трёх стадий: softmax на $K+1$ классов (с фоном) + регрессоры поправок на каждый класс ($4K$ выходов); сквозное обучение.


Rol pooling



Вырезанные блоки карты признаков — разного размера, а голове нужен фиксированный.

Rol pooling (идея пирамидального пулинга из сегментации): режем регион фиксированной сеткой, в каждой ячейке — максимум по каналу. Любой регион $\rightarrow$ одинаковое число признаков.

Позже появился аккуратный Rol align: без округления границ, с билинейной интерполяцией — он используется в Mask R-CNN.





регион $\rightarrow$ сетка $2 \times 2 \rightarrow 4$ признака

Программировать неприятно: не свёртка, своя маска на каждый регион — авторы спускались до CUDA-ядер.

Faster R-CNN (2015): сеть предлагает регионы



Selective search — чужеродный и медленный. Пусть регионы предлагает такая же сеть: **Region Proposal Network (RPN)**.




Скользящее окно 3×3 по карте признаков — реализуется свёрткой 3×3 + 1×1 до 256 каналов; из них — $2k$ скоров «объект/нет» и $4k$ поправок для k якорей.

Якоря и разметка RPN



Якоря — стандартные рамки с центром в текущей позиции: 3 масштаба (128^2 , 256^2 , 512^2) × 3 соотношения (1:1, 1:2, 2:1) = 9 на позицию.

Разметка: якорь с $\text{IoU} > 0,7$ с истиной — «объект»;
плюс для каждой истинной рамки — якорь с максимальным IoU , чтобы у каждой рамки был свой позитивный якорь.



Отбор кандидатов: убрать вылезшие за край
→ топ-6000 по вероятности объекта → NMS
→ 2000 на обучении / 300 на тесте.

Обучение — 4 стадии: RPN → Fast R-CNN на его регионах → снова RPN → всё вместе end-to-end.

Эволюция скорости



Метод	Время на кадр
R-CNN	49 с
SPP-Net	4,3 с
Fast R-CNN	2,3 с
Faster R-CNN	0,2 с


- Два порядка на тесте; обучение — с 84 до 8,75 часа, mAP при этом вырос (66,0 → 68,1).
- Это **двухстадийные** детекторы: сначала разреженные кандидаты, потом детекция по ним.

Но 0,2 с = ~7 кадров в секунду — до реального времени (25) всё ещё далеко.


FPN: пирамида признаков




До сих пор якоря и прогнозы жили на одной сжатой карте.
Знакомая по сегментации мысль: так невыгодно.



(a) Featurized image pyramid



(b) Single feature map



(c) Pyramidal feature hierarchy



(d) Feature Pyramid Network

(a) пирамида копий — дорого; (b) одна карта — грубо; (c) ранние слои — слабые признаки; (d) FPN: проход назад + латеральные связи (Lin et al., 2017)

FPN: механика

- Проход назад: upscale $\times 2$, латеральная связь через 1×1 , **сложение** (как в LinkNet), сверху 3×3 .
- Якоря — по уровням: на каждом один масштаб $\times 3$ соотношения; размеры получаются автоматически.
- К какому уровню относить найденный регион — по размеру:

$$k = \left\lfloor k_0 + \log_2(\sqrt{wh} / 224) \right\rfloor$$


Регион канонического размера 224×224 — на базовый уровень k_0 ; вдвое больше — уровнем грубее, вдвое меньше — детальнее. Faster R-CNN обычно реализуют сразу с FPN.

YOLO (2015): you only look once




Одностадийная идея: один проход — сразу и регионы, и классы.

- Сетка $S \times S$ (7×7); ячейка предсказывает B рамок (2) с $P(\text{Object})$ и вектор классов.
- Выход — один тензор $S \times S \times (5B + K)$.
- Объект приписывается ячейке со своим центром и ближайшей по форме рамке.
- Лосс — квадратичный для всего сразу.




YOLO: результат и цена

Combine bboxes and class probabilities



Apply NMS and probability thresholding



- Честный real-time: **45 FPS**, YOLO-tiny — 155; вход 448x448, Leaky ReLU, предобучение 20 слоёв на ImageNet.
- Цена: максимум B объектов на ячейку — толпа и мелкие объекты страдают; mAP ниже двухстадийных.

SSD (2016)




Якоря (как в RPN) в каждой позиции **нескольких масштабов** промежуточных карт; для каждого — сразу softmax по классам с фоном + 4 поправки.


Отличия от YOLO:

- нет отдельного $P(\text{Object})$;
- backbone VGG (не Darknet);
- hard negative mining 1:3;
- якоря на масштабах снимают лимит объектов на ячейку.

8732 якоря, **59 FPS** при mAP 74,3.



(a) Image with GT boxes (b) 8×8 feature map (c) 4×4 feature map




Много регионов default boxes на разных масштабах.

RetinaNet (2017)



Одностадийность + FPN: над каждым уровнем пирамиды — две свёрточные подсети, class subnet и box subnet.



Lin et al., 2017

Плюс главная добавка — **focal loss** — на следующем слайде.


Focal loss

Дисбаланс: фоновых якорей на порядки больше; лёгкие примеры ($p \approx 1$) по чуть-чуть, но суммарно перевешивают трудные.

$$\mathcal{L}_{\text{focal}} = -(1-p)^{\gamma} \log p$$

Лёгкое ($p \rightarrow 1$) обнуляется, трудное — как обычная кросс-энтропия. Лучшее $\gamma = 2$.

Это и есть наследник hard negative mining — та же идея одной формулой, без итераций.



RetinaNet = FPN + focal loss: state-of-the-art одностадийник своего времени.

Итоги: качество и скорость

Метод	mAP	FPS
DPM v5	33,7	0,07
R-CNN	66,0	0,05
Fast R-CNN	70,0	0,5
Faster R-CNN	73,2	7
YOLO	69,0	45

(Pascal VOC 2007)

- Сети сразу удвоили качество досетевых методов.
- **Двухстадийные** — качественнее, медленнее.
- **Одностадийные** — порядок скорости за несколько пунктов mAP.
- **Anchor-free** — без якорей и их инженерии: следующий слайд.

Anchor-free: FCOS



Классифицируем не якоря, а **точки**:

- точка внутри истинной рамки — позитив;
- предсказывает (l, t, r, b) — расстояния до сторон;
- + **center-ness**: близость к центру, домножается на вероятность класса — кривые рамки с краёв выпадают сами.

Поверх FPN (P_3 – P_7), обучается focal loss'ом.
Родственники: CornerNet, CenterNet;
трансформерный DETR — после блока про внимание.



Figure 3 – Center-ness. Red, blue, and other colors denote 1, 0 and the values between them, respectively. Center-ness is computed by Eq. (9) and decays from 1 to 0 as the location deviates from the center of the object. When testing, the center-ness predicted by the network is multiplied with the classification score thus can down-weight the low-quality bounding boxes predicted by a location far from the center of an object.

В каждой точке предсказывается (l, t, r, b) ,
а не (x, y, w, h) + класс (метка из C) + центральность (число).

$$\text{centerness}^* = \sqrt{\frac{\min(l^*, r^*)}{\max(l^*, r^*)} \times \frac{\min(t^*, b^*)}{\max(t^*, b^*)}}.$$


Center-ness на $[0, 1]$ обучается с помощью binary cross-entropy (BCE) loss.

При работе к точкам с большим значением можно применить NMS.

В классификации вместо softmax — мультикласс.

Tian et al., 2019

Десятилетие детекции — и что дальше



- Методы выходят каждый год: под конкретную задачу имеет смысл открыть свежую статью — база для этого теперь есть.
- Блок «регулярной решётки» завершён. На следующей неделе — **3D-данные** (облака точек, PointNet) и **графовые сети**; тексты — неделей позже.



Обратная связь

